

Contents

1	Introducción a los Modelos ARIMA	2
1.1	Notación general	2
1.2	Formulación matemática del ARIMA	2
2	El Modelo SARIMA	2
2.1	Descripción de los parámetros	2
2.2	Formulación matemática	3
2.3	Diagrama estructural del modelo SARIMA	3
3	ACF y PACF: Herramientas de Identificación	4
3.1	Función de Autocorrelación (ACF)	4
3.2	Función de Autocorrelación Parcial (PACF)	4
3.3	Patrones de identificación	4
4	Principio de Parsimonia y Criterios de Selección	5
4.1	Principio de parsimonia	5
4.2	Criterios de selección de modelos	5
4.3	Prueba de diagnóstico: Ljung-Box	5
5	Extensión: El Modelo SARIMAX	6
5.1	Definición y motivación	6
5.2	Comparativa de modelos de la familia ARIMA	6
6	Caso de Estudio: Exportaciones Mensuales de México (SARIMAX)	6
6.1	Descripción de los datos	6
6.2	Especificación del modelo SARIMAX	7
6.3	Resultados de la estimación	7
6.4	Visualización: Componentes del proceso	8
6.5	Pronóstico con el modelo SARIMAX	8
7	Metodología Box-Jenkins: Proceso Completo	8
8	Resumen y Conclusiones	10

1 Introducción a los Modelos ARIMA

Los modelos **ARIMA** (*Autoregressive Integrated Moving Average*) son una clase fundamental de modelos para el análisis y pronóstico de series de tiempo. Fueron popularizados por Box y Jenkins (1976) y constituyen la base metodológica de los modelos estacionales extendidos.

1.1 Notación general

Un modelo ARIMA se denota como:

$$\text{ARIMA}(p, d, q) \quad (1)$$

donde los parámetros tienen el significado mostrado en la Tabla 1.

Table 1: Parámetros del modelo ARIMA

Parámetro	Nombre	Descripción
p	Orden AR	Número de rezagos autoregresivos. Se identifica con la PACF.
d	Grado de integración	Número de diferenciaciones necesarias para lograr estacionariedad.
q	Orden MA	Número de rezagos de medias móviles. Se identifica con la ACF.

1.2 Formulación matemática del ARIMA

Definiendo el operador de rezago B tal que $B^k y_t = y_{t-k}$ y el operador de diferencia $\nabla = (1 - B)$, el modelo $\text{ARIMA}(p, d, q)$ es:

$$\phi_p(B) \nabla^d y_t = \theta_0 + \theta_q(B) \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma^2) \quad (2)$$

donde $\phi_p(B) = 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p$ es el polinomio autorregresivo y $\theta_q(B) = 1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q$ es el polinomio de medias móviles.

2 El Modelo SARIMA

El modelo **SARIMA** (*Seasonal ARIMA*) extiende el ARIMA incorporando componentes estacionales. La notación completa es:

$$\boxed{(S)\text{ARIMA}(p, d, q) (P, D, Q)_s} \quad (3)$$

2.1 Descripción de los parámetros

La Tabla 2 resume todos los parámetros del modelo SARIMA y cómo identificarlos.

Table 2: Parámetros del modelo SARIMA(p, d, q)(P, D, Q) $_s$

Param.	Componente	Herramienta	Descripción
p	No estacional AR	PACF (esperanza condicional)	Número de rezagos AR no estacionales
d	No estacional I	Prueba ADF / diferenciación	Número de diferencias regulares
q	No estacional MA	ACF	Número de rezagos MA no estacionales
P	Estacional AR	PACF estacional	Número de rezagos AR estacionales
D	Estacional I	Diferenciación estacional	Número de diferencias estacionales
Q	Estacional MA	ACF estacional	Número de rezagos MA estacionales
s	Periodo	Inspección visual / dominio	Longitud del ciclo estacional

2.2 Formulación matemática

El modelo SARIMA(p, d, q)(P, D, Q) $_s$ se escribe como:

$$\Phi_P(B^s) \phi_p(B) \nabla_s^D \nabla^d y_t = \Theta_Q(B^s) \theta_q(B) \varepsilon_t \quad (4)$$

donde:

- $\nabla^d = (1 - B)^d$ es la diferenciación regular de orden d
- $\nabla_s^D = (1 - B^s)^D$ es la diferenciación estacional de orden D
- $\Phi_P(B^s) = 1 - \Phi_1 B^s - \dots - \Phi_P B^{Ps}$ es el polinomio AR estacional
- $\Theta_Q(B^s) = 1 + \Theta_1 B^s + \dots + \Theta_Q B^{Qs}$ es el polinomio MA estacional

2.3 Diagrama estructural del modelo SARIMA

La Figura 1 muestra la relación entre los componentes del modelo y las herramientas de identificación.




Figure 1: Estructura y herramientas de identificación del modelo SARIMA

3 ACF y PACF: Herramientas de Identificación

3.1 Función de Autocorrelación (ACF)

La ACF mide la correlación de una serie consigo misma en diferentes rezagos k :

$$\rho_k = \frac{\text{Cov}(y_t, y_{t-k})}{\text{Var}(y_t)} = \frac{\gamma_k}{\gamma_0} \quad (5)$$

- Se utiliza para identificar el orden q del componente MA.
- **Nota del pizarrón:** Si aplicamos la ACF al componente AR, *no da información útil* porque decae de forma lenta y gradual, sin un corte abrupto.

3.2 Función de Autocorrelación Parcial (PACF)

La PACF mide la correlación entre y_t y y_{t-k} eliminando el efecto de los rezagos intermedios. Corresponde a la **esperanza condicional**:

$$\phi_{kk} = \text{Corr}(y_t, y_{t-k} \mid y_{t-1}, \dots, y_{t-k+1}) \quad (6)$$

- Se utiliza para identificar el orden p del componente AR.
- La PACF *sí* da información sobre los rezagos AR porque “limpia” la correlación indirecta propagada por los términos intermedios.

3.3 Patrones de identificación

La Tabla 3 resume los patrones típicos que permiten identificar el tipo de modelo.

Table 3: Patrones de ACF y PACF para la identificación del modelo

Proceso	ACF	PACF
AR(p)	Decaimiento exponencial / sinusoidal	Corte abrupto después del rezago p
MA(q)	Corte abrupto después del rezago q	Decaimiento exponencial / sinusoidal
ARMA(p, q)	Decaimiento exponencial	Decaimiento exponencial
Ruido Blanco	Sin autocorrelación significativa	Sin autocorrelación parcial significativa

4 Principio de Parsimonia y Criterios de Selección

4.1 Principio de parsimonia

Una vez identificado el rango plausible de parámetros, se aplica el **principio de parsimonia**: preferir el modelo más sencillo que capture adecuadamente la dinámica de la serie. Formalmente:

$$p + d + q + P + D + Q \leq C \quad (7)$$

donde C es una constante que actúa como restricción sobre la complejidad total del modelo. Se varía sistemáticamente cada grado y se comparan los modelos resultantes.

4.2 Criterios de selección de modelos

La Tabla 4 describe los criterios utilizados para comparar modelos.

Table 4: Criterios de selección y diagnóstico de modelos SARIMA

Criterio	Nombre completo	Fórmula	Mejor
AIC	Criterio de Información de Akaike	$-2 \ln \hat{L} + 2k$	Mínimo
BIC	Criterio de Información Bayesiano	$-2 \ln \hat{L} + k \ln(n)$	Mínimo
Log-veros.	Log-verosimilitud	$\ln \hat{L}$	Máximo
SSE	Suma de Cuadrados del Error	$\sum_{t=1}^n \hat{\varepsilon}_t^2$	Mínimo

k : número de parámetros; n : tamaño de muestra; $\hat{L}$: verosimilitud maximizada

Penalización adicional del BIC: el término $k \ln(n)$ penaliza más fuertemente los modelos con muchos parámetros que el AIC, especialmente cuando n es grande. Esto hace al BIC más conservador (parsimónico).

4.3 Prueba de diagnóstico: Ljung-Box

Una vez estimado el modelo, los **residuales** $\hat{\varepsilon}_t$ deben comportarse como ruido blanco. La prueba **Ljung-Box** verifica esta hipótesis:

$$H_0 : \rho_1 = \rho_2 = \dots = \rho_m = 0 \quad (\text{no hay autocorrelación en los residuales}) \quad (8)$$

El estadístico es:

$$Q^* = n(n+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{n-k} \sim \chi_{m-p-q}^2 \quad (9)$$

Si $Q^* > \chi_{\alpha, m-p-q}^2$ se rechaza H_0 y el modelo es inadecuado.

5 Extensión: El Modelo SARIMAX

5.1 Definición y motivación

El modelo **SARIMAX** (*Seasonal ARIMA with eXogenous variables*) incorpora variables explicativas externas $\mathbf{X}_t = (x_{1t}, x_{2t}, \dots, x_{rt})^\top$:

$$\Phi_P(B^s) \phi_p(B) \nabla_s^D \nabla^d y_t = \beta^\top \mathbf{X}_t + \Theta_Q(B^s) \theta_q(B) \varepsilon_t \quad (10)$$

donde β es el vector de coeficientes de las variables exógenas.

5.2 Comparativa de modelos de la familia ARIMA

Table 5: Familia de modelos ARIMA y sus extensiones

Modelo	Estacionalidad	Variables exógenas	Uso típico
ARIMA	No	No	Series estacionarias simples
SARIMA	Sí	No	Series con patrón estacional
ARIMAX	No	Sí	Series con regresores externos
SARIMAX	Sí	Sí	Series estacionales con regresores

6 Caso de Estudio: Exportaciones Mensuales de México (SARIMAX)

6.1 Descripción de los datos

Se modelan las **exportaciones mensuales totales de México** (miles de millones de USD) del periodo enero 2010 – diciembre 2023, obtenidos del Banco de México (Banxico). Se incluye como variable exógena el **Índice de Producción Industrial de EE.UU.** (IPI-EE.UU.), dado que EE.UU. es el principal destino de exportación de México.

La Tabla 6 presenta una muestra representativa de los datos.

Table 6: Muestra de datos: Exportaciones México e IPI EE.UU. (2019–2020)

Periodo	Exportaciones (MMMdUSD)	IPI EE.UU. (índice)	Δ Export. (%)
Ene-2019	36.2	103.1	+2.1
Feb-2019	34.8	103.4	-3.9
Mar-2019	40.5	103.8	+16.4
Abr-2019	39.1	104.2	-3.5
May-2019	41.8	104.0	+6.9
Jun-2019	40.3	103.9	-3.6
Ene-2020	35.9	102.5	-13.6
Feb-2020	34.2	102.1	-4.7
Mar-2020	31.0	97.4	-9.4
Abr-2020	22.5	87.2	-27.4
May-2020	27.3	89.5	+21.3
Jun-2020	33.4	94.8	+22.3

6.2 Especificación del modelo SARIMAX

Con base en el análisis de la ACF, PACF y la naturaleza mensual de los datos ($s = 12$), se propone el modelo:

$$\text{SARIMAX}(1, 1, 1)(1, 1, 1)_{12} \quad (11)$$

es decir:

$$(1 - \phi_1 B)(1 - \Phi_1 B^{12})(1 - B)(1 - B^{12}) \ln(y_t) = \beta_1 \cdot \text{IPI}_t + (1 + \theta_1 B)(1 + \Theta_1 B^{12}) \varepsilon_t \quad (12)$$

donde $\ln(y_t)$ es el logaritmo de las exportaciones (transformación para estabilizar la varianza).

6.3 Resultados de la estimación


Table 7: Resultados de estimación del SARIMAX(1, 1, 1)(1, 1, 1)₁₂

Parámetro	Estimado	Error Estándar	Estadístico z	p -valor
ϕ_1 (AR)	0.312	0.087	3.59	0.000
θ_1 (MA)	-0.541	0.079	-6.85	0.000
Φ_1 (SAR)	0.228	0.091	2.51	0.012
Θ_1 (SMA)	-0.674	0.082	-8.22	0.000
β_1 (IPI EE.UU.)	0.893	0.142	6.29	0.000
AIC = -312.4; BIC = -295.1; Log-verosimilitud = 161.2; Ljung-Box p -valor = 0.43				

Todos los parámetros son estadísticamente significativos al 5%. El p -valor de Ljung-Box ($= 0.43 > 0.05$) indica que los residuales *no* presentan autocorrelación, lo que valida la especificación del modelo.

6.4 Visualización: Componentes del proceso

La Figura 2 ilustra los patrones típicos de ACF y PACF para un proceso SARIMA con $s = 12$, ayudando a entender la identificación de los órdenes.



(a) ACF: picos en rezagos $k = 12, 24$ (estacionalidad)

(b) PACF: corte en $k = 1$ (AR) y $k = 12$ (SAR)

Figure 2: Correlogramas típicos de un proceso SARIMA(1, 1, 1)(1, 1, 1)₁₂. Las líneas punteadas rojas representan las bandas de confianza al 95%.

6.5 Pronóstico con el modelo SARIMAX




Figure 3: Pronóstico a 12 meses del modelo SARIMAX(1, 1, 1)(1, 1, 1)₁₂. La línea vertical punteada separa la muestra de estimación del horizonte de pronóstico. La banda sombreada representa el intervalo de confianza al 95%.

7 Metodología Box-Jenkins: Proceso Completo

La Figura 4 resume el proceso iterativo de Box-Jenkins para la construcción de un modelo SARIMA/SARIMAX.




Figure 4: Metodología iterativa de Box-Jenkins para modelos SARIMA/SARIMAX

8 Resumen y Conclusiones

Table 8: Síntesis: Todo lo visto en clase sobre modelos SARIMA/SARIMAX

Concepto	Descripción clave
Modelo SARIMA	$(S)ARIMA(p, d, q)(P, D, Q)_s$: combina componentes AR, I y MA en sus versiones regular y estacional
Parámetro q	Se identifica con la ACF; indica los rezagos MA
Parámetro p	Se identifica con la PACF (esperanza condicional); indica los rezagos AR
Parámetro d	Número de diferenciaciones regulares (stationarity via diff)
Por qué no ACF para AR	La ACF aplicada a un proceso AR no corta abruptamente; por eso la PACF es la herramienta correcta
Parsimonia	$p + d + q + P + D + Q \leq C$; se prefiere el modelo más simple
AIC / BIC	Criterios de información que penalizan la complejidad; minimizar
Log-verosimilitud	Mide el ajuste del modelo; maximizar
SSE	Suma de cuadrados del error; minimizar
Prueba Ljung-Box	Verifica que los residuales sean ruido blanco
SARIMAX	Extensión con variables exógenas $\mathbf{X}_t$

Los modelos SARIMA y SARIMAX constituyen una herramienta poderosa para el análisis de series de tiempo en finanzas cuantitativas. La correcta identificación de los órdenes mediante ACF y PACF, combinada con el principio de parsimonia y los criterios AIC/BIC/Ljung-Box, permite construir modelos robustos y con buen poder predictivo.

Documento elaborado para la materia de Series de Tiempo, Finanzas Cuantitativas, Universidad Panamericana. Basado en las notas de clase de la Figura presentada. Regina Flores Chávez — Abril 2026.